






主讲人: 耿海直



团队介绍





队长:何哲宇(@RinChanNOWWW)

队员: 耿海直(@JmPotato)、黄梦龙(@disksing)



项目背景

TIDB HACKATHON 2021

理论上的灾难恢复 v.s. 实际上的灾难恢复



- 硬件故障
- 断网断电
- 洪水
- 海啸
- 地震
- 太阳黑子异常活动
- 核战争
- 彗星撞地球

- 出 bug 写坏数据
- 有漏洞被黑客攻击
- drop 错数据库
- delete 忘加 where
- 删库跑路
- ◆ 宇宙射线导致比特位翻转



TiDB 的现状





"天灾易躲,人祸难防",现有的功能和计划中的功能对 DML 造成的数据问题处理都太弱了:

- 对于需要排查数据损坏的情况,查看某条记录的变化历史太麻烦
- RECOVER TABLE 只能恢复 DROP/TRUNCATE 这种 DDL 操作, 对 DML 没招
- GC SafePoint 之前的数据恢复不了
- 备份恢复需要经历 Dump 再写入的过程





项目解决了什么问题?

TIDB HACKATHON 2021

对于 MVCC 的思考



- 一段时间内的旧版本都在,只要数据没有被 GC,理论上可以进行快速恢复
- MVCC 数据是非常"结构化"的,完全有可能使用 SQL 的方式来进行读写操作
- MVCC 不只是可以用来暂时性地处理事务隔离,也完全可以做为冷备,相比于外部的备份, 其优点是可以更省空间,恢复数据也更方便更快
- 如果需要回滚某段时间的写入,并不一定要真的删除或覆盖实际数据,可以使用轻量级"标记删除"的方式,跳过特定时间段的 MVCC 版本就行了







Make MVCC Great Again!



方案对比





| | TIDB | TiDB + MVCC 时光机 | |
|------------|--|--|--|
| 排查数据变更历史 | 用 debug 接口查看 raw 数据, 或者设置 snapshot_ts 查询某个时间点的数据 | 使用 SQL 查询所有版本, 并可以 进行各种条件 过滤 | |
| 误删/误写坏数据 | recover table 只能处理 drop/truncate table | 支持恢复各种 delete 或 update | |
| 回滚数据 | 只能先 dump 出来再重新覆盖写入, 操作复 杂, 恢 复速度慢 | 使用一条 flashback 命令,在亚秒级时间完成恢复 (一次DDL同步) | |
| 长时间保留历史数据 | 更新频繁时占用大量磁盘空间, 还影响性能 | 通过设置 save point, 使用最少的空间保留多份 Point-in-Time 数据 | |
| 外部数据备份历史数据 | 消耗额外资源同步数据, 恢复数据耗 时长 | 直接通过 save point 备份数据, 充分利用 TiDB 的高可用等特性, 而且恢复数据又快又方便 | |

TIDB HACKATHON 2021



Hackathon 上实现了哪些内容?



Hackathon 上实现了哪些内容?



谁掌握了过去,谁就掌握了未来;谁掌握了现在,谁就掌握过去。

- 直接通过 SQL 增删改查数据的 MVCC 记录 -> 操纵过去
- 瞬间 Flashback 一张表到任意时刻 → 掌控现在
- 保留表的指定版本,有备而无患 -> 着眼未来



MVCC Query in SQL

PingCAP




- 带上虚拟列(_tidb_mvcc_op __tidb_mvcc_ts)查询,可以MVCC 版本
- 可以在查询条件中添加针对的过滤条件,只显示符合条件
- 可以使用子查询的方式还原昇4 rows in set (0.01 sec)
- 帯上虚拟列的 UPDATE 操作直 | _tidb_rowid | a MVCC 记录, 不会新增 PUT 记 ! N

```
mysql> select * from t;
 rows in set (0.01 sec)
mysql> select _tidb_rowid, a, _tidb_mvcc_ts, _tidb_mvcc_op from t;
  _tidb_rowid | a
                      _tidb_mvcc_ts
                                           _tidb_mvcc_op
                NULL
                       430325081203539970
                                           Delete
                       430325069158285315
                                            Put
                       430325069158285315
                                            Put
                       430325069158285315
mysql> select _tidb_rowid, a, _tidb_mvcc_ts, _tidb_mvcc_op from t where _tidb_mvcc_op = 'Delete';
                       _tidb_mvcc_ts
                                            _tidb_mvcc_op
                      430325081203539970
                                          Delete
1 row in set (0.01 sec)
mysql> select _tidb_rowid, a, _tidb_mvcc_ts, _tidb_mvcc_op from t where _tidb_mvcc_ts < 430325081203539970;
                      _tidb_mvcc_ts
  _tidb_rowid | a
                                           _tidb_mvcc_op
                       430325069158285315
                                           Put
                       430325069158285315
                                            Put
                       430325069158285315
3 rows in set (0.01 sec)
```

MVCC Query in SQL








TIDB HACKATHON 2021

GC SavePoint



- 新增新系统表 gc_save_point,并可以通过 SQL 进行管理
- 新增新 GC 配置项
 gc_save_point_interval 和
 gc_save_point_lifetime, 用于系统自动
 创建 save point
- GC 之后,每个 SavePoint 前的最后一个版本数据会被保留
- 使用历史读或者 MVCC Query in SQL 查询时,可以展示 GC 按预期运行



Subsecond Flashback





- 添加 *FLASH TABLE TO TIMESTAMP TS* SQL 语句,用于指定表进行数据还原,意义是将表还原至不超过某个时间戳指定的版本
 - 快+轻量——并不是真的删除新数据
 - 表信息里加入了一个区间: [flashback_ts, now_ts]
 - DDL 操作进行更新
 - TiKV 扫描时跳过对应 TS 区间的 Key
 - 缺点 & 改进
- 还原后启动新事务进行查询,看到旧版本的数据





Demo







mysql> select * from t; 2 rows in set (0.01 sec) mysql> select _tidb_rowid, a, _tidb_mvcc_ts, _tidb_mvcc_op from t; _tidb_rowid | a | _tidb_mvcc_ts _tidb_mvcc_op NULL 430325081203539970 Delete 1 430325069158285315 Put 430325069158285315 Put 430325069158285315 4 rows in set (0.01 sec) mysql> select _tidb_rowid, a, _tidb_mvcc_ts, _tidb_mvcc_op from t where _tidb_mvcc_op = 'Delete'; _tidb_rowid | a _tidb_mvcc_ts _tidb_mvcc_op 1 | NULL | 430325081203539970 | Delete 1 row in set (0.01 sec) mysql> select _tidb_rowid, a, _tidb_mvcc_ts, _tidb_mvcc_op from t where _tidb_mvcc_ts < 430325081203539970; _tidb_rowid | a _tidb_mvcc_ts _tidb_mvcc_op 430325069158285315 430325069158285315 2 Put 430325069158285315 3 rows in set (0.01 sec)

Select







```
mysql> select * from t;
2 rows in set (0.00 sec)
mysql> update t set a = 4 where a = 2;
Query OK, 1 row affected (0.01 sec)
Rows matched: 1 Changed: 1 Warnings: 0
mysql> select * from t;
2 rows in set (0.00 sec)
mysql> select _tidb_rowid, a, _tidb_mvcc_ts, _tidb_mvcc_op from t;
  _tidb_rowid | a
                     _tidb_mvcc_ts
                                           _tidb_mvcc_op
               NULL
                                           Delete
                      430325081203539970
                      430325069158285315
                                           Put
            2
                      430325117799104514
                                           Put
                      430325069158285315
                                            Put
                      430325069158285315
                                           Put
5 rows in set (0.01 sec)
```

Update



```
mysql> select * from t;
2 rows in set (0.01 sec)
mysql> delete from t where a = 3;
Query OK, 1 row affected (0.02 sec)
mysql> select * from t;
1 row in set (0.01 sec)
mysql> select _tidb_rowid, a, _tidb_mvcc_ts, _tidb_mvcc_op from t;
  _tidb_rowid | a
                     _tidb_mvcc_ts
                                            _tidb_mvcc_op
                                            Delete
                NULL
                       430325081203539970
                       430325069158285315
                                            Put
            2
                       430325117799104514
                                            Put
            2
                       430325069158285315
                                            Put
                NULL
                       430325134458355715
                                            Delete
                       430325069158285315
                                            Put
```

6 rows in set (0.00 sec)





Delete



```
mysql> select * From t;
1 row in set (0.00 sec)
mysql> update t set a = 2 where _tidb_mvcc_ts = 430318915147268099;
Query OK, 0 rows affected (0.01 sec)
Rows matched: 0 Changed: 0 Warnings: 0
mysql> select _tidb_rowid, a, _tidb_mvcc_ts, _tidb_mvcc_op from t;
  _tidb_rowid | a | _tidb_mvcc_ts
                                         | _tidb_mvcc_op |
                   1 | 430319471658008579 | Put
1 row in set (0.01 sec)
mysql> update t set a = 2 where _tidb_mvcc_ts = 430319471658008579;
Query OK, 1 row affected (0.02 sec)
Rows matched: 1 Changed: 1 Warnings: 0
mysql> select _tidb_rowid, a, _tidb_mvcc_ts, _tidb_mvcc_op from t;
                    tidb mvcc ts
  _tidb_rowid | a
                                          _tidb_mvcc_op |
                2 | 430319471658008579 | Put
1 row in set (0.01 sec)
mysql> select * from t;
1 row in set (0.01 sec)
```





Update By MVCC



mysql> select * from t;

```
1 row in set (0.00 sec)
mysql> update t set a = 3 where a = 2;
Query OK, 1 row affected (0.07 sec)
Rows matched: 1 Changed: 1 Warnings: 0
mysql> select * from t;
1 row in set (0.01 sec)
mysql> select _tidb_rowid, a, _tidb_mvcc_ts, _tidb_mvcc_op from t;
  _tidb_rowid | a | _tidb_mvcc_ts
                                         | tidb mvcc op |
                  3 | 430320878286274562 | Put
                   2 | 430319471658008579 | Put
2 rows in set (0.00 sec)
mysql> update t set a = 4 where _tidb_mvcc_ts = 430319471658008579;
Query OK, 1 row affected (0.08 sec)
Rows matched: 1 Changed: 1 Warnings: 0
mysql> select _tidb_rowid, a, _tidb_mvcc_ts, _tidb_mvcc_op from t;
  _tidb_rowid | a
                    _tidb_mvcc_ts
                                         _tidb_mvcc_op
                  3 | 430320878286274562 | Put
                   4 | 430319471658008579 | Put
2 rows in set (0.00 sec)
mysql> select * from t;
1 row in set (0.01 sec)
```





Update By MVCC



测试结果 - GC SavePoint



```
mysql> select VARIABLE NAME, VARIABLE VALUE from tidb where VARIABLE NAME like '%sa
ve point%';
                                | VARIABLE_VALUE
 VARIABLE NAME
 tikv gc save point interval | 1h0m0s
tikv_gc_save_point_life_time | 24h0m0s
2 rows in set (0.01 \text{ sec})
mysql> select * from gc save point;
 save point
 2022-01-08 06:00:00
 2022-01-08 07:00:00
 2022-01-08 08:00:00
 2022-01-08 09:00:00
 2022-01-08 10:00:00
  2022-01-08 11:00:00
6 rows in set (0.00 sec)
```

新增系统表 gc_save_point 记录 gc_safe_point 之外额外的多个存档点

新增 save_point_interval 和 save_point_life_time 配置用于系统定时自动创建和回收 save point



测试结果 - GC SavePoint



mysql> mysql> select _tidb_rowid, TIDB_PARSE_TSO(_tidb_mvcc_ts), _tidb_mvcc_op, a from t
by tidb mvcc ts limit 20;

| _tidb_rowid | TIDB_PARSE_TSO(_tidb_mvcc_ts) | _tidb_mvcc_op | a | |
|-------------|-------------------------------|---------------|---------|---------------|
| 1 | 2022-01-08 11:09:54.941000 | Put | hello1 | |
| 1 | 2022-01-08 11:14:54.504000 | Put | hello14 | |
| 1 | 2022-01-08 11:19:54.055000 | Put | hello27 | |
| 1 | 2022-01-08 11:24:53.504000 | Put | hello40 | |
| 1 | 2022-01-08 11:29:53.005000 | Put | hello53 | |
| 1 | 2022-01-08 11:34:52.606000 | Put | hello66 | gc_safe_point |
| 1 | 2022-01-08 11:36:47.856000 | Put | hello71 | 0 |
| 1 | 2022-01-08 11:37:10.906000 | Put | hello72 | |
| 1 | 2022-01-08 11:37:33.907000 | Put | hello73 | |
| 1 | 2022-01-08 11:37:56.957000 | Put | hello74 | |
| 1 | 2022-01-08 11:38:20.006000 | Put | hello75 | |
| 1 | 2022-01-08 11:38:43.057000 | Put | hello76 | |
| 1 | 2022-01-08 11:39:06.106000 | Put | hello77 | |
| 1 | 2022-01-08 11:39:29.157000 | Put | hello78 | |
| 1 | 2022-01-08 11:39:52.157000 | Put | hello79 | |
| 1 | 2022-01-08 11:40:15.206000 | Put | hello80 | |
| 1 | 2022-01-08 11:40:38.256000 | Put | hello81 | |
| 1 | 2022-01-08 11:41:01.307000 | l Put i | hello82 | |
| 1 | 2022-01-08 11:41:24.357000 | Put i | hello83 | |
| 1 | 2022-01-08 11:41:47.407000 | Put i | hello84 | |

20 rows in set (0.00 sec)

设置 gc_save_point_interval = '5m' 后 在 gc_safe_point 之前, 本来会 被回收 mvcc 记录每 5 分钟保 留一个版本



测试结果 - Subsecond Flashback





```
mysql> select * from dodo list;
Empty set (0.00 sec)
mysql> select NOW();
  NOW()
 2022-01-07 23:57:09
1 row in set (0.00 sec)
mysql> insert into dodo_list values ("金色渡渡鸟");
Query OK, 1 row affected (0.00 sec)
mysql> select * from dodo_list;
  dodo_name
  金色渡渡鸟
1 row in set (0.00 sec)
mysql> flashback table dodo_list to timestamp '2022-01-07 23:57:09';
Query OK, 0 rows affected (0.06 sec)
mysql> select * from dodo list;
Empty set (0.00 sec)
```

Flashback



测试结果 - Subsecond Flashback





mysql> select _tidb_rowid, dodo_name from dodo_list; _tidb_rowid | dodo_name 3 rows in set (0.00 sec) mysql> select _tidb_rowid, dodo_name, _tidb_mvcc_ts, _tidb_mvcc_op from dodo_list order by _tidb_mvcc_ts desc; +-----不愿透露姓名的渡渡鸟 430328363639635970 430328362577690626 Put 430328361215066115 | Put 4 rows in set (0.00 sec) mysql> select TIDB_PARSE_TSO(430328379040333826); TIDB PARSE TSO(430328379040333826) 2022-01-08 00:21:30.846000 1 row in set (0.00 sec) mysql> flashback table dodo_list to timestamp '2022-01-08 00:21:29'; Query OK, 0 rows affected (0.09 sec) mysql> select tidb rowid, dodo name from dodo list; tidb rowid | dodo name 元初渡渡鸟 3 rows in set (0.00 sec)

根据 MVCC 记录 Flashback





未来展望

TIDB HACKATHON 2021

未来展望





- 目前仅基于 TableScan 进行了 Demo, 要想完全适配还有一些工作要做
- 与生态工具的兼容性问题
- Flashback 操作和 MVCC Query 的组合拳
 - 查看 Flashback 记录
 - 撤销 Flashback 操作
 - 修改 Flashback 记录



Thanks

